

Tratamento de Incertezas

Raciocínio Probabilístico

Raciocínio Probabilístico

- O Raciocínio Probabilístico é talvez o mais antigo que trata com mecanismos de incerteza. A teoria da probabilidade oferece uma maneira quantitativa de codificar incertezas.
- Apóia-se em informações probabilísticas sobre fatos de um domínio e chega a uma conclusão a respeito de um novo fato, conclusão esta, que fica associada a uma probabilidade.
 - Possui uma semântica clara
 - Probabilidades podem ser obtidas a partir de dados.
 - Permite incorporar novas evidências facilmente.

Raciocínio Probabilístico

- Frequentistas x Bayesianos
 - Quando se fala de probabilidade neste contexto, não se faz referência a números, e sim, a um tipo de raciocínio.
- Exemplo:
 - “A chance de que um paciente portador da doença D apresente no futuro próximo o sintoma S é p ”.
 - A verdade desta afirmação não é o valor preciso de p , mas um valor de crença do médico.

Fundamentos

- **Experimento Aleatório**
 - Um experimento aleatório, E , é um experimento em que o resultado não pode ser predito, mesmo que seja repetido várias vezes e nas mesmas condições.
 - Experimentos:
 - E1: "Arremesso de moeda".
 - E2: "Arremesso de 2 moedas".
 - E3: "Arremesso de dado".
 - E4: "Retirar uma bola de uma urna contendo bolas numeradas de 1 a 100".
 - Variáveis aleatórias:
 - E1: "Face da moeda para cima".
 - E2: "Faces de 2 moedas para cima".
 - E3: "Face do dado para cima".
 - E4: "Número da bola"

Fundamentos

- **Espaço amostral**
 - É o conjunto de todos os valores que a variável aleatória pode assumir.
 - Exemplos de espaços amostrais:
 - $E1: \{\text{cara, coroa}\}$
 - $E2: \{(\text{cara, cara}), (\text{cara, coroa}), (\text{coroa, cara}), (\text{coroa, coroa})\}$
ou $E2: \{(\text{cara, cara}), (\text{cara, coroa}), (\text{coroa, coroa})\}$ (se a ordem não é relevante)
 - $E3: \{1, 2, 3, 4, 5, 6\}$
 - $E4: \{1, 2, \dots, 100\}$
 - Classificação dos Espaços Amostrais
 - Discreto x Contínuo
 - Finito x Infinito

Fundamentos

- **Eventos**
 - Um evento é um subconjunto do espaço amostral.
- **Exemplos:**
 - E1: "Jogar uma moeda três vezes e observar quantas vezes aparece cara e quantas vezes aparece coroa".
 - Subconjunto: $\{(kkc), (kck), (ckk)\}$
 - E2: "Jogar um dado e observar o número na face de cima".
 - Evento: "Número é par".
 - Subconjunto: $\{2,4,6\}$

Fundamentos

- **Variável Aleatória**

- É aquela que assume valores num espaço amostral e para a qual está determinada a probabilidade de ocorrência de cada um dos elementos do espaço amostral.
- Se o espaço amostral for contínuo, é necessário conhecer a função distribuição de probabilidade para caracterizar a variável aleatória.
- Se o espaço amostral for discreto, é necessário conhecer a função massa de probabilidade para caracterizar a variável aleatória.

Fundamentos

- Probabilidade

- $\Pr[A]$ = É a medida da **chance** de um evento A ocorrer.
- Probabilidade como Frequência Relativa:
 - Sequência de repetições do experimento sob idênticas condições
 - f_n = número de ocorrências de A nas primeiras n repetições.
 - f_n/n = fração dos experimentos em que A ocorre nas primeiras n repetições. Quando n cresce, esta fração tende a se estabilizar.
 - Se o espaço amostral consiste de N elementos igualmente prováveis e o evento A corresponde a um subconjunto de r elementos do espaço amostral, então a probabilidade de ocorrer A é dada por: $\Pr[A] = r / N$

Fundamentos

- **Probabilidade**

- Exemplo: Uma urna contém 10 bolas numeradas de 0 a 9. Num experimento é preciso selecionar uma bola da urna e anotar seu número. Deseja-se encontrar a probabilidade dos eventos:

$A = \text{"número da bola é 5"}$

$B = \text{"número da bola é ímpar"}$

$C = \text{"número da bola é múltiplo de 3"}$

- O espaço amostral é $S=\{0,1,...,9\}$ e os resultados correspondentes aos eventos acima são:

$A=\{5\}$ $B=\{1,3,5,7,9\}$ $C=\{3,6,9\}$

- Se for suposto que os resultados são equiprováveis, então:

$$\Pr[A] = \Pr[5] = 1/10$$

$$\Pr[B] = \Pr[1] + \Pr[3] + \Pr[5] + \Pr[7] + \Pr[9] = 1/10 + 1/10 + 1/10 + 1/10 + 1/10 = 5/10.$$

$$\Pr[C] = \Pr[3] + \Pr[6] + \Pr[9] = 1/10 + 1/10 + 1/10 = 3/10.$$

Fundamentos

- **Probabilidade Conjunta**
 - Fornece a probabilidade de dois ou mais eventos ocorrerem simultaneamente.
 - Ao se jogar uma moeda duas vezes, temos os eventos:
 $A = \{\text{Obter cara (k) na primeira jogada}\} \rightarrow \Pr[A] = 1/2$
 $B = \{\text{Obter cara (k) na segunda jogada também}\} \rightarrow \Pr[B] = 1/2$
 - Logo,
$$\Pr[AB] = \Pr[A]\Pr[B] = \frac{1}{2} * \frac{1}{2} = \frac{1}{4}$$
 - Atenção!!!
 - $\Pr[AB] = \Pr[A]\Pr[B]$
 - Só é válida se os eventos forem independentes, como no exemplo anterior.

Fundamentos

- **Probabilidade A Priori**

- A probabilidade a priori, também chamada de probabilidade incondicional, de um evento é a probabilidade atribuída a um evento na ausência de conhecimento que suporte a sua ocorrência ou ausência, isto é, a probabilidade do evento anterior a qualquer evidência.
- A probabilidade a priori é simbolizada por $\text{Pr}[\text{evento}]$.

- **Probabilidade Posterior**

- A probabilidade posterior (após o fato), também chamada probabilidade condicional, de um evento é a probabilidade de um evento dada alguma evidência.
- A probabilidade posterior é simbolizada por $R[\text{evento} \mid \text{evidência}]$.

Fundamentos

- **Probabilidade Condicional**
 - Eventos cujas ocorrências estão interligadas. A ocorrência de um deles afeta a probabilidade de ocorrência do outro.
 - Exemplo: Escolher aleatoriamente uma palavra num dicionário.
 - Evento A: A letra u aparece na palavra;
 - Evento B: A letra q aparece na palavra.
 - Se sabemos que B ocorre, a nossa estimativa da probabilidade de ocorrência de A é alterada.

Fundamentos

- **Probabilidade Condicional**
 - Definição: Probabilidade Condicional de A dado B (i.e., Probabilidade Condicional de ocorrer A , dado que sabemos que B ocorre).
 - $\Pr[A|B] = \Pr[A \cap B] / \Pr[B]$, com $\Pr[B] \neq 0$
 - $\Pr[A|B]$ é a probabilidade de $A \cap B$ relativamente a probabilidade de B .
- **Eventos INDEPENDENTES:**
 - $\Pr[A|B] = \Pr[A] \Leftrightarrow \Pr[A \cap B] = \Pr[A]\Pr[B]$
 - Ocorrência de B não afeta a probabilidade de A .

Fundamentos

- **Probabilidade Condicional**
 - A probabilidade condicional responde questões do tipo:
 - “Dado que ocorreu o evento A , qual a probabilidade de ocorrer o evento B ?”
 - Por exemplo:
 - Qual a probabilidade de um paciente estar com cárie, dado que ele está com dor de dente?
 - Qual a probabilidade de chover, dado que o céu está completamente nublado?

Fundamentos

- Probabilidade Condicional
 - Um experimento consiste em jogar um dado uma vez.
 - Sejam os eventos:
 - A: "Número na face é 6"
 - B: "Número na face é maior que 4"
 - O dado foi jogado, qual a probabilidade de ocorrer evento A (sair 6), sabendo que o evento B ocorreu?
 - $\Pr[A|B] = \Pr[AB] / \Pr[B]$
 - $= 1/6 / 1/3$
 - $= 1/2$

Raciocínio Probabilístico

- Teorema de Bayes:

- Seja:

- $\Pr[A|B]$ a probabilidade de que a hipótese A seja verdadeira dada a evidência B .
 - $\Pr[B|A]$ a probabilidade que a evidência B será observada se a hipótese A for verdadeira.
 - $\Pr[A]$ a probabilidade “a priori” que a hipótese A é verdadeira na ausência de qualquer evidência específica.
 - $\Pr[B]$ a probabilidade “a priori” que a evidência B é verdadeira na ausência de qualquer evidência específica.

- $\Pr[A|B] = \Pr[A, B] / \Pr[B]$

- $\Pr[B|A] = \Pr[B, A] / \Pr[A]$

Como $\Pr[A, B] = \Pr[B, A]$

- $\Pr[A|B] = \Pr[B|A] * \Pr[A] / \Pr[B]$

Raciocínio Probabilístico

- Teorema de Bayes:
 - Se A_1, A_2, \dots, A_K são eventos mutuamente exclusivos, dos quais um deve ocorrer, então a regra de Bayes pode ser generalizada para:
 - $\Pr[A | B] = \Pr[B | A] * \Pr[A] / \sum_{n=0}^K \Pr[B | A_n] * \Pr[A_n]$

Raciocínio Probabilístico


- Exemplo Introdutório:
 - Imagine que você é um homem que tem em mãos um exame de sangue (seu) que diz: soropositivo para HIV.
 - Passa pela sua cabeça a imagem do médico a dizer: "você tem uma chance de 999/1000 de morrer em menos de uma década (ou, uma chance em mil de estar saudável). Eu realmente sinto muito."
 - De onde ele tirou isso? Da seguinte estatística: o exame de HIV gera 1 resultado falso positivo para cada 1 mil amostras de sangue. Para entender o erro do médico, vamos a Bayes. Definir o espaço amostral:
 - A) verdadeiros positivos
 - B) falsos positivos
 - C) verdadeiros negativos
 - D) falsos negativos

Raciocínio Probabilístico

- Exemplo Introdutório:
 - Ah sim, você não é um homem qualquer. Você é branco, norte-americano, heterossexual e não usuário de drogas injetáveis. Vamos seguir a seguinte estatística: 1 de cada 10 mil homens com essas características está infectado. Vamos tratar de uma população de 10 mil então.
 - Sendo a taxa de falsos negativos próxima de zero, 1 pessoa de cada 10 mil tem um verdadeiro positivo. Como a taxa de falsos positivos é, segundo o médico, $1/1000$, haverá 10 outros casos de falsos positivos. Os outros 9.989 homens apresentarão exames negativos.
 - Que resultados são “favoráveis” no espaço amostral? Os positivos, A e B. Queremos saber se somos falsos ou verdadeiros positivos. Acabamos com 10 pessoas falso positivos e 1 verdadeiro positivo. Em outras palavras, 1 pessoa em 11 está de fato infectada. Ou ainda, chance de $10/11$ de ser falso positivo.

Raciocínio Probabilístico



- Exemplo Introdutório:
 - Em uma cidade existem duas companhias de taxis, os azuis e os verdes. 15% das taxis são azuis e 85% dos taxis são verdes.
 - Em um acidente noturno, uma testemunha assegurou ter visto um taxi azul envolvido no acidente.
 - Experimentos conduzidos pela polícia atestaram que esta testemunha era capaz de acertar a cor de um taxi sob as mesmas condições de iluminação em 80% das vezes.
 - De que cor era o taxi envolvido no acidente?



De cada 100 taxis, 15 são azuis e 85 são verdes.

Raciocínio Probabilístico

- Exemplo Introdutório:
 - Em uma cidade existem duas companhias de taxis, os azuis e os verdes. 15% das taxis são azuis e 85% dos taxis são verdes.
 - Em um acidente noturno, uma testemunha assegurou ter visto um taxi azul envolvido no acidente.
 - Experimentos conduzidos pela polícia atestaram que esta testemunha era capaz de acertar a cor de um taxi sob as mesmas condições de iluminação em 80% das vezes.
 - De que cor era o taxi envolvido no acidente?



De cada 100 taxis, 15 – (20%) são azuis e vistos azuis e 85 – (20%) são verdes e vistos como verdes. Mas 20% dos 85 são verdes mas vistos como azuis e 20% dos 15 são azuis mas vistos como verdes.

Raciocínio Probabilístico

- Exemplo Introdutório:

- Em uma cidade existem duas companhias de taxis, os azuis e os verdes. 15% das taxis são azuis e 85% dos taxis são verdes.
- Em um acidente noturno, uma testemunha assegurou ter visto um taxi azul envolvido no acidente.
- Experimentos conduzidos pela polícia atestaram que esta testemunha era capaz de acertar a cor de um taxi sob as mesmas condições de iluminação em 80% das vezes.
- De que cor era o taxi envolvido no acidente?

A	VA	
Verdade	Verdade	$15 \cdot 0.8 = 12$
Verdade	Falso	$15 \cdot 0.2 = 3$
Falso	Verdade	$85 \cdot 0.2 = 17$
Falso	Falso	$85 \cdot 0.8 = 68$

$$|\text{Azul}| = 15 \quad |\text{Visto Azul}| = 29 \quad |\text{Azul} \cap \text{Visto Azul}| = 12$$

$$|\text{Verde}| = 85 \quad |\text{Visto Verde}| = 71 \quad |\text{Verde} \cap \text{Visto Verde}| = 68$$

Raciocínio Probabilístico

- Exemplo Introdutório
 - $\Pr[A|B] = \Pr[AB] / \Pr[B]$
 - A : Taxi é azul
 - B : Taxi foi visto azul

	Visto Azul	Visto Verde	Total
Azul	12	3	15
Verde	17	68	85
Total	29	71	100

- $\Pr[A|B] =$
 $=$
 $=$
 $\Pr[AB] / \Pr[B]$
 $12/29$
 $0,413$

Raciocínio Probabilístico

- Aplicando o Teorema de Bayes no Problema dos Taxis:
 - A = hipótese = taxi envolvido no acidente ser REALMENTE azul;
 - B = evidência = a testemunha ver um taxi de cor azul.
 - $\Pr[B|A]$ = percentagem das vezes em que a testemunha viu um taxi azul e o taxi era REALMENTE azul = 80%
 - $\Pr[A]$ = probabilidade a priori. Percentagem das vezes em que um taxi é azul = 15%.
 - $\Pr[B]$ = probabilidade a priori. Percentagem das vezes que a testemunha vê um taxi azul = $12 + 17 = 29\%$.
- $\Pr[A|B] = 0.8 * 0.15 / 0.29 = 0.413 \sim 41\%$

Raciocínio Probabilístico

- Outro Exemplo:
 - Um médico sabe que meningite causa dor no pescoço em 50% dos casos. Ele sabe que a probabilidade a priori de um paciente ter meningite (M) é $1/50000$ e a probabilidade a priori de qualquer paciente ter uma dor no pescoço (S) é $1/20$.
 - Tem-se que:
 - $\Pr[S|M] = 1/2$
 - $\Pr[M] = 1/50000$
 - $\Pr[S] = 1/20$
 - Um paciente chega ao consultório com dor no pescoço. Qual a probabilidade dele estar com meningite - $\Pr[M|S]$?
 - $\Pr[M|S] = \Pr[S|M]\Pr[M] / \Pr[S] = 1/2 * 1/50000 / 1/20 = 0.0002$

Raciocínio Probabilístico

- Outro Exemplo:
 - Ou seja, é esperado que apenas 1 em 5000 pacientes com torcicolo tenha meningite.

Raciocínio Probabilístico


- Teorema de Bayes
 - O que é importante no Teorema de Bayes é que os valores no lado direito da equação para $Pr[d|s]$ podem ser facilmente obtidos, pelo menos quando comparamos com o lado esquerdo da equação.
 - É muito mais fácil determinar o número de pacientes com meningite que tem dor no pescoço, do que determinar a percentagem entre aqueles que sofrem de dor no pescoço e tem meningite.
 - Quando consideramos cada doença e cada sintoma isoladamente, temos $m \times n$ medidas para coletar e integrar (na realidade são $m \times n$ probabilidades posteriores mais $m+n$ probabilidades a priori).

Redes Bayesianas

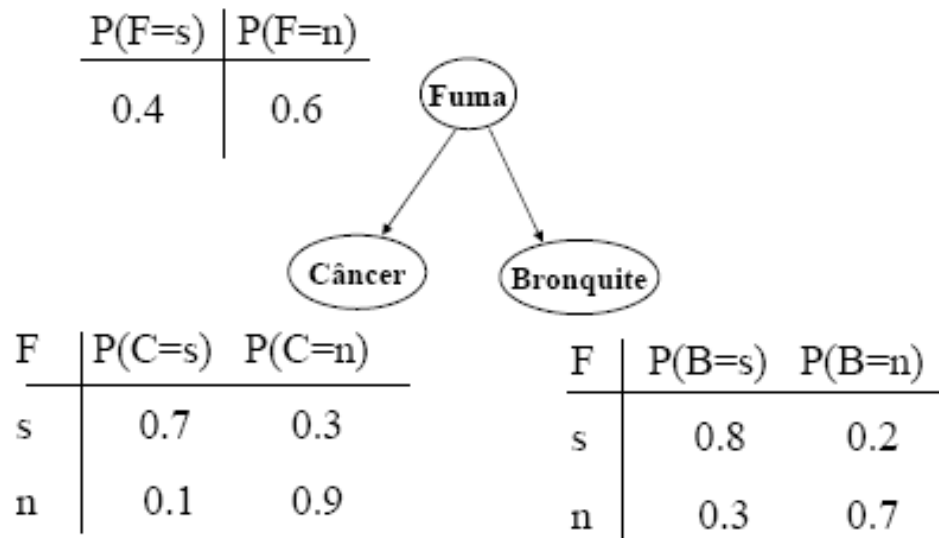
- Como representar o conhecimento em sistemas inteligentes que utilizam o raciocínio probabilístico?
Uma alternativa é usar Redes Bayesianas!!
- Rede Bayesiana é uma ferramenta gráfica para raciocínio e representação de conhecimento frente a incertezas.
- Ela é uma representação compacta da distribuição de probabilidades conjuntas do universo do problema.
- Formalmente, é um grafo acíclico direcionado Os nós (também chamados de variáveis) são os eventos que queremos modelar.

Redes Bayesianas

- Os arcos ligando os nós indicam a presença de um dependência entre eles.
- Cada nó possui uma tabela de probabilidades, dizendo as chances de ocorrer o evento representado por ele (inclusive probabilidade condicional).




Redes Bayesianas



- Qual a probabilidade de alguém ter câncer, sabendo que ela fuma? $\Pr[C|F] = 0.7$
- Qual a probabilidade de alguém ter bronquite, dado que ela fuma? $\Pr[B|F] = 0.8$
- Qual a porcentagem de pessoas que fumam? $\Pr[F] = 0.4$

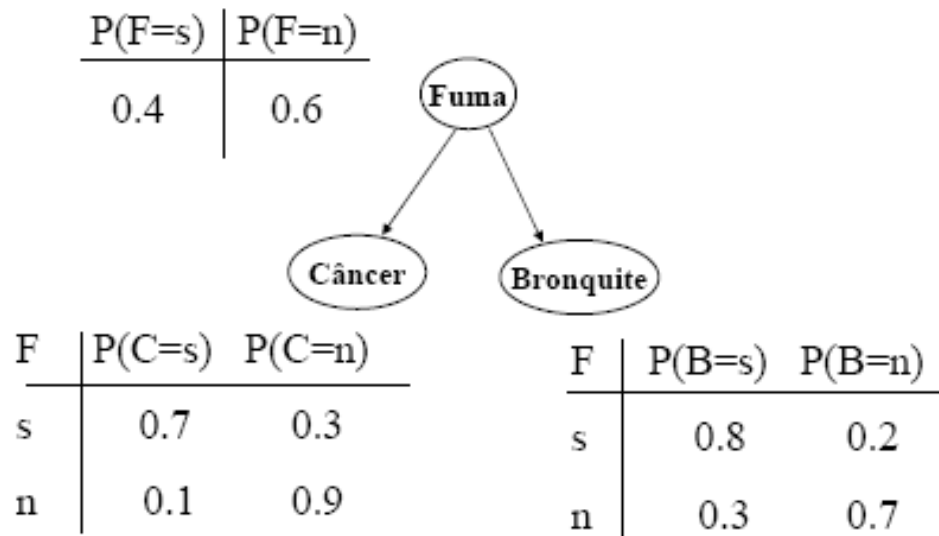
Redes Bayesianas



- Sabendo que uma pessoa está com câncer, qual a probabilidade desta pessoa ser fumante?

$$\begin{aligned}
 \Pr[F|C] &= \Pr[C|F].\Pr[F] / (\Pr[C|F].\Pr[F] + \Pr[C|nF].\Pr[nF]) \\
 &= 0,7.0,4 / (0,7.0,4 + 0,1.0,6) = 0,28/0,34 \\
 &= 0,823 \rightarrow 82\% \text{ de ser fumante}
 \end{aligned}$$

Redes Bayesianas



- Sabendo que uma pessoa está com bronquite, qual a probabilidade desta pessoa ter câncer?

$$\Pr[C|B] = \Pr[C|F].\Pr[F|B] + \Pr[C|nF].\Pr[nF|B]$$

$$\Pr[F|B] = \Pr[B|F].\Pr[F] / (\Pr[B|F].\Pr[F] + \Pr[B|nF].\Pr[nF])$$

$$= 0,8.0,4 / (0,8.0,4 + 0,3.0,6) = 0,64$$

Redes Bayesianas

- Sabendo que uma pessoa está com bronquite, qual a probabilidade desta pessoa ter câncer?

$$\Pr[C|B] = \Pr[C|F].\Pr[F|B] + \Pr[C|\neg F].\Pr[\neg F|B]$$

$$\Pr[F|B] = \Pr[B|F].\Pr[F] / (\Pr[B|F].\Pr[F] + \Pr[B|\neg F].\Pr[\neg F])$$

$$= 0,8.0,4 / (0,8.0,4 + 0,3.0,6) = 0,64$$

$$\Pr[C|F] = 0,7$$

$$\Pr[F|B] = 0,64$$

$$\Pr[C|\neg F] = 0,1$$

$$\Pr[\neg F|B] = 0,36$$


$$\begin{aligned}\Pr[C|B] &= 0,7.0,64 + 0,1.0,36 = 0,448 + 0,036 \\ &= 0,484 \rightarrow 48,4\%\end{aligned}$$

Redes Bayesianas

- Outro Exemplo:
 - Você instalou um alarme contra roubos na sua casa, que dispara em caso de invasão.
 - Infelizmente, o alarme é sensível a terremotos
 - Quando o alarme disparar, seus 2 vizinhos, João e Maria, disseram que vão te ligar.
 - João as vezes confunde o alarme com a sirene do carro de bombeiros.
 - Maria ouve música num volume alto e nem sempre escuta o alarme
 - João te ligou.
 - Qual a probabilidade de estarem roubando sua casa???

Redes Bayesianas

- Outro Exemplo:



Raciocínio Probabilístico

- Hoje em dia se fala da probabilidade subjetiva.
- Ela trata com eventos que não tem uma base histórica sobre a qual se possa extrapolar.
- A probabilidade subjetiva é uma crença ou opinião expressa como uma probabilidade.
- Exemplo:
 - Em SE para diagnóstico médico, um evento poderia ser:
 - $E = \text{"O paciente está coberto com manchas vermelhas"}$
 - e a proposição é:
 - $A = \text{"O paciente tem sarampo"}$.
 - A probabilidade condicional $\Pr[A \mid E]$ não é uma probabilidade no sentido clássico ou frequencista.
 - Ela pode ser interpretada como o grau de crença que A é verdadeiro dado o evento E .

Raciocínio Probabilístico

- Atualmente existem shells para o desenvolvimento de Sistemas Especialistas com raciocínio probabilista, dentre eles tem-se o SPIRIT, o HUGIN e o NETICA.
- Dificuldades com o Método Bayesiano
 - A obtenção das probabilidades das hipóteses H_i e as condicionais $Pr[H_i | e]$ é considerado uma tarefa difícil porque as pessoas não sabem estimar probabilidades. No entanto, as estimativas necessárias de probabilidade são feitas pelo especialista a partir de seu conhecimento e experiência no domínio pesquisado.
 - A base de conhecimento tem que ser completa. Isto é, todas as evidências relevantes às hipóteses consideradas devem estar explícitas na base de conhecimento.
 - Em probabilidade parte-se do fato que as evidências são independentes. Isto nem sempre é verdadeiro no caso das doenças, posto que alguns sintomas poderiam ser evidência de outros.

Raciocínio Probabilístico

- Exercícios:

1. Suppose there are two full bowls of cookies. Bowl #1 has 10 chocolate chip and 30 plain cookies, while bowl #2 has 20 of each. Our friend Fred picks a bowl at random, and then picks a cookie at random. We may assume there is no reason to believe Fred treats one bowl differently from another, likewise for the cookies. The cookie turns out to be a plain one. How probable is it that Fred picked it out of Bowl #1?

2. (desafio) The blue M&M was introduced in 1995. Before then, the color mix in a bag of plain M&Ms was (30% Brown, 20% Yellow, 20% Red, 10% Green, 10% Orange, 10% Tan). Afterward it was (24% Blue, 20% Green, 16% Orange, 14% Yellow, 13% Red, 13% Brown).

A friend of mine has two bags of M&Ms, and he tells me that one is from 1994 and one from 1996. He won't tell me which is which, but he gives me one M&M from each bag. One is yellow and one is green. What is the probability that the yellow M&M came from the 1994 bag?